

TỪ ĐIỂN DỮ LIỆU (DATA DICTIONARY)

Mục	Nội dung
Nhóm thực hiện	Liên minh Nhóm 7 và 8 (Tuần 4–9 / 2026)
Giai đoạn	Bài tập 2 – Thu thập và tổ chức dữ liệu
Nguồn thô	cafeland_raw.csv (9.883 × 9) · bat_dong_san_raw.xls (30.149 × 9) · chotot_bds_dataset.xls (5.000 × 14, chỉ khảo sát)
Tập làm sạch lần 1	data/interim/df_raw.csv (11.888 dòng × 10 cột)
Tập làm sạch lần 2	data/processed/df_clean.csv (7.436 dòng × 27 cột)
Mã nguồn tạo ra số liệu	notebooks/02_lam_sach_du_lieu.ipynb, notebooks/02_lam_sach_du_lieu_2.ipynb; src/data/lam_sach_du_lieu.py; src/features/tao_dac_trung.py; data/interim/loai_ape_lan_chay_goc.csv
Thành viên	1. Trần Thị Ngọc Ánh (24639511) · 2. Nguyễn Bá Công (24689091) · 3. Hà Trọng Hữu Duy (24702061) 4. Lê Anh Duy (24681951) · 5. Nguyễn Thị Trâm (24689661) · 6. Văn Tường Vy (24648771)

1. Tổng quan các tập dữ liệu

Dữ liệu đi qua ba mức: **thô** (cào từ web) → **làm sạch lần 1** (df_raw: quy đổi số, lọc TP.HCM, gắn quận) → **làm sạch lần 2** (df_clean: bỏ nhãn trống, khử trùng, lọc ngoại lai, tạo đặc trưng, loại tin sai số dự đoán lớn). Mọi con số trong tài liệu này được sinh ra khi chạy lại hai notebook làm sạch.

Mức	Tập	Định dạng	Dung lượng	Quy mô	Ghi chú
Thô	data/raw/cafeland_raw.csv	CSV UTF-8	9,58 MB	9.883 × 9	Nguồn chính
Thô	data/raw/bat_dong_san_raw.xls	CSV UTF-8-sig	51,30 MB	30.149 × 9	Nguồn bổ sung. Đuôi .xls nhưng là văn bản CSV, đọc bằng pd.read_csv
Thô	data/raw/chotot_bds_dataset.xls	CSV	1,20 MB	5.000 × 14	Nguồn dự phòng, chỉ khảo sát, không gộp (mục 5.5)
Sạch lần 1	data/interim/df_raw.csv	CSV UTF-8	17,24 MB	11.888 × 10	Hai sàn, TP.HCM, có quận/huyện. Bản nhóm đã chốt
Sạch lần 2	data/processed/df_clean.csv	CSV UTF-8	11,04 MB	7.436 × 27	Dùng cho EDA (BT3) và mô hình (BT4)

Yêu cầu tối thiểu của đề cương là ≥ 5.000 dòng và ≥ 8 biến: df_raw có 11.888 dòng, 10 biến; df_clean có 7.436 dòng, 27 biến. Mỗi dòng ghi rõ nguồn (cafeland hoặc batdongsan) và giữ url gốc.

Thời điểm dữ liệu. CafeLand: 9.461/9.883 tin có ngày đăng năm 2026 (phần còn lại không có ngày).

Batdongsan: 11.883 tin năm 2026, 8.144 tin năm 2025, 10.122 tin năm 2024. df_raw và df_clean không giữ cột ngày, nên dữ liệu được xem là một lát cắt tại thời điểm cào (31/08–01/09/2026).

2. Từ điển df_raw.csv (làm sạch lần 1 – 10 biến)

Tạo từ dữ liệu thô bằng hàm tao_df_raw() (notebook 02_lam_sach_du_lieu). Chạy lại cho cùng 11.888 dòng và cùng phân bố nguồn; 99,23% URL trùng với bản đã chốt (khác biệt do lần chạy gốc sắp xếp không ổn định khi khử trùng chéo nguồn). Tài liệu này mô tả bản đã chốt. Phân bố nguồn: batdongsan 8.374 tin (70,44%), cafeland 3.514 tin (29,56%). Không có dòng trùng, url duy nhất 11.888/11.888. Cột duy nhất còn ô trống là loai_hinh (2.809 dòng).

#	Biến	Kiểu	Đơn vị	Ý nghĩa và khoảng giá trị	Vai trò
1	tieu_de	object	văn bản	Tiêu đề tin. 11.886 giá trị khác nhau.	Nguồn trích đặc trưng ở df_clean
2	gia_ban	float64	triệu VNĐ	Giá niêm yết đã quy đổi. Min 109; trung vị 6.990; TB 9.568,22; max 44.000. Độ lệch 1,89.	Biến mục tiêu
3	dien_tich_m2	float64	m ²	Min 10; trung vị 70; TB 81,01; max 270. Độ lệch 1,53.	Biến giải thích chính
4	tinh_thanh	object	danh mục	100% "TP. Hồ Chí Minh".	Xác nhận phạm vi; bỏ ở

#	Biến	Kiểu	Đơn vị	Ý nghĩa và khoảng giá trị	Vai trò
					df_clean
5	quan_huyen	object	danh mục	20 quận/huyện, trích từ mô tả. Nhiều nhất: Quận 12 (1.281), Quận 7 (928), Quận 1 (909), Gò Vấp (908), Bình Tân (877). Ít nhất: Nhà Bè (130), Quận 5 (145). Không có Củ Chi, Bình Chánh, Cần Giờ.	Biến vị trí cho câu hỏi Q2
6	mo_ta_dac_diem	object	văn bản	Mô tả tin. 11.874 giá trị khác nhau; 14 mô tả trùng (đăng lại).	Nguồn trích đặc trưng
7	loai_hinh	object	danh mục	10 nhãn chưa thống nhất + 2.809 ô trống (đều từ batdongsan). "Nhà riêng" 4.273; "căn hộ" 1.222; "Nhà phố" 1.181; 3 nhãn nhỏ cộng lại 13 tin.	Chuẩn hóa còn 8 nhóm ở df_clean
8	nguồn_du_lieu	object	danh mục	batdongsan 8.374; cafeland 3.514.	Đối chiếu hai nguồn
9	url	object	đường dẫn	11.888/11.888 giá trị khác nhau.	Khóa chính; không đưa vào mô hình
10	gia_moi_m2_trieu	float64	triệu/m²	Giá ÷ diện tích. Min 1,18; trung vị 107,69; TB 126,53; max 2.500. Độ lệch 4,39.	Chỉ để mô tả; bỏ ở df_clean vì rò rỉ nhãn

3. Từ điển df_clean.csv (làm sạch lần 2 – 27 biến)

Tạo bởi notebook 02_lam_sach_du_lieu_2 (trùng khớp với hàm tạo df_clean()). 7.436 dòng = 62,55% df_raw. Nguồn: batdongsan 4.400 (59,17%), cafeland 3.036 (40,83%). Không còn ô trống. Lưu ý: hai cột kích thước ghi –1 khi tin không nêu số; hai cột địa danh ghi Khong_ro khi không trích được — đây là chỗ thiếu đã đánh dấu, không phải giá trị thật.

#	Biến	Nhóm	Kiểu	Đơn vị	Mô tả, khoảng giá trị, cách dùng
1	gia_ban	Giá	float64	triệu VNĐ	Min 340; trung vị 7.500; TB 9.970,76; max 44.000. Độ lệch 1,76. Biến mục tiêu.
2	log_gia_ban	Giá	float64	ln(triệu)	Min 5,83; trung vị 8,92; max 10,69. Độ lệch 0,09.
3	dien_tich_m2	Diện tích	float64	m²	Min 15; trung vị 72; TB 84,75; max 270. Độ lệch 1,46. Tương quan với giá 0,57.
4	log_dien_tich	Diện tích	float64	ln(m²)	Min 2,71; trung vị 4,28; max 5,60. Độ lệch 0,05.
5	quan_huyen	Vị trí	object	danh mục	20 quận/huyện. Nhiều nhất: Quận 12 (682), Quận 1 (606), Quận 7 (600), Gò Vấp (581), Thủ Đức (524). Ít nhất: Nhà Bè (71), Quận 5 (89).
6	phuong	Vị trí	object	danh mục	347 giá trị. Khong_ro 5.001 dòng (67,25%). 785 dòng chỉ là số ("7", "12") — dễ trùng giữa các quận. Không one-hot trực tiếp.
7	ten_duong	Vị trí	object	danh mục	1.332 giá trị. Khong_ro 2.884 dòng (38,78%). Gặp nhiều: Huỳnh Tấn Phát (108), Quang Trung (82).
8	loai_hinh	Loại nhà	object	danh mục	8 nhóm (bảng 3.1).
9	so_phong_ngu	Quy mô	float64	phòng	Trích từ chữ ("3pn"); trần 10. Thiếu thì điền trung vị theo loại nhà. Min 1; trung vị 3; TB 3,47; max 10. 26,22% là số điền thay (xem co_tt_phong_ngu).
10	so_tang	Quy mô	float64	tầng	Trích từ chữ; trần 8; không nêu thì ghi 1. Min 1; trung vị 2; TB 2,58; max 8.
11	so_wc	Quy mô	float64	phòng	Trần 8; thiếu thì lấy số phòng ngủ (tối đa 4). Min 1; trung vị 3; TB 3,18. Tương quan với số phòng ngủ 0,73.
12	mat_tien_m	Kích thước	float64	mét	–1 khi không có số (5.823 dòng, 78,31%). 1.613 tin có số: min 2,3; trung vị 5,0; max 30.
13	rong_hem_m	Kích thước	float64	mét	–1 khi không có số (6.558 dòng, 88,19%). 878 tin có số: min 2; trung vị 6; max 15.
14	mat_do_xay	Quy mô	float64	m² sàn ước lượng	Diện tích × số tầng. Min 15; trung vị 159; TB 216,36; max 2.080. Tương quan với số tầng 0,70.
15	la_hem	Đặc điểm	int64	0/1	1 khi có chữ hẻm/hẽm. 3.150 tin (42,36%).
16	la_mat_tien	Đặc điểm	int64	0/1	1 khi có chữ mặt tiền/mặt phố. 3.322 tin (44,67%).
17	co_so_hong	Đặc điểm	int64	0/1	1 khi có số hồng/sổ đỏ/SHR/pháp lý rõ. 4.180 tin (56,21%).
18	co_noi_that	Đặc điểm	int64	0/1	1 khi có chữ nội thất. 1.289 tin (17,33%).
19	oto_vao	Đặc điểm	int64	0/1	1 khi có ô tô/oto/xe hơi. 2.570 tin (34,56%).

#	Biến	Nhóm	Kiểu	Đơn vị	Mô tả, khoảng giá trị, cách dùng
20	gan_truong_cho	Đặc điểm	int64	0/1	1 khi có trường học/chợ/siêu thị/bệnh viện. 3.473 tin (46,71%).
21	chinh_chu	Đặc điểm	int64	0/1	1 khi có chữ chính chủ. 2.115 tin (28,44%). Môi giới cũng hay viết.
22	co_tt_phong_ngu	Đánh dấu	int64	0/1	1 nếu tin có ghi số phòng ngủ (5.486 tin, 73,78%); 0 nếu so_phong_ngu là số điền thay.
23	co_tt_mat_tien	Đánh dấu	int64	0/1	1 nếu mat_tien_m > 0 (1.613 tin, 21,69%). Đọc cùng mat_tien_m.
24	nguồn_du_lieu	Nguồn	object	danh mục	batdongsan 4.400; cafeland 3.036. Dùng kiểm soát lệch nguồn.
25	tieu_de_sach	Văn bản	object	văn bản	Tiêu đề đã thay cụm "số + đơn vị" (tỷ, triệu, m2...) bằng <SO>. 7.368 giá trị khác nhau; 90,09% vẫn còn chữ số (2PN, 4x15).
26	mo_ta_sach	Văn bản	object	văn bản	Mô tả đã che như trên. 7.432 giá trị khác nhau; 99,99% còn chữ số. Không đưa thô vào mô hình giá.
27	url	Mã tin	object	đường dẫn	7.436/7.436 khác nhau; toàn bộ nằm trong df_raw.

3.1. Loại nhà và đơn giá

Đơn giá = giá ÷ diện tích, chỉ tính để mô tả, không lưu trong df_clean.

Loại hình	Số tin	Tỉ lệ (%)	Trung vị giá (triệu)	Trung vị diện tích (m²)	Trung vị đơn giá (triệu/m²)
Nhà riêng	3.580	48,14	7.225	65	118,14
Nhà phố	970	13,04	6.985	64	115,05
Căn hộ	949	12,76	6.000	70	78,43
Nhà mặt tiền	801	10,77	10.500	88	121,17
Đất	680	9,14	6.200	100	68,07
Biệt thự	425	5,72	14.000	126	115,38
Shophouse	24	0,32	7.500	102	62,05
Khác	7	0,09	16.800	160	85,71

Quận/huyện	Số tin	Trung vị đơn giá	Quận/huyện	Số tin	Trung vị đơn giá
Quận 5	89	208,1	Quận Gò Vấp	581	119,8
Quận 3	246	196,6	Quận 8	436	112,7
Quận 10	254	181,6	Quận Tân Phú	522	109,2
Quận 1	606	175,7	Quận 6	207	103,4
Quận 11	163	140,6	Quận Bình Tân	514	88,8
Quận Bình Thạnh	460	136,9	Quận 9	357	80,0
Quận Tân Bình	456	135,4	Quận 12	682	75,0
Quận 4	127	121,9	Huyện Nhà Bè	71	74,3
Quận 2	368	121,9	TP. Thủ Đức	524	72,2
Quận 7	600	121,9	Huyện Hóc Môn	173	46,0

4. Từ df_raw sang df_clean

#	Cột ở df_raw	Cột ở df_clean	Việc đã làm
1	tieu_de	tieu_de_sach	Che cụm "số + đơn vị" bằng <SO> để mô hình không đọc được giá viết trong tiêu đề.
2	gia_ban	gia_ban, log_gia_ban	Lọc theo đơn giá (mục 4.1); tạo log.
3	dien_tich_m2	dien_tich_m2, log_dien_tich	Giữ 15–500 m²; tạo log.
4	ting_thanh	(bỏ)	Chỉ có một giá trị.
5	quan_huyen	quan_huyen	Giữ nguyên.

#	Cột ở df_raw	Cột ở df_clean	Việc đã làm
6	mo_ta_dac_diem	17 cột trích từ chữ + mo_ta_sach	Trích số phòng, tầng, WC, mặt tiền, hẻm, phường, đường, 7 cò 0/1, 2 cò đánh dấu; che số.
7	loai_hinh	loai_hinh	Bỏ dòng trống; sửa "Nhà riêng", "căn hộ"; gom 3 nhãn nhỏ vào "Khác" (10 nhãn → 8 nhóm).
8	nguồn_du_lieu	nguồn_du_lieu	Giữ nguyên.
9	url	url	Giữ nguyên làm khóa.
10	gia_moi_m2_trieu	(bỏ)	Bảng giá ÷ diện tích → rõ ràng.

4.1. Kiểm toán 4.452 dòng bị loại

Bảng này được in trực tiếp ở mục 12 của notebook 02_lam_sach_du_lieu_2, có lệnh assert kiểm tra số dòng loại + số dòng giữ = 11.888, và hàm tao_df_clean() cho đúng kết quả như notebook.

Bước (theo thứ tự chạy)	Số dòng loại	% trên df_raw	Lý do
1. Thiếu nhãn loại hình	2.809	23,63	Toàn bộ thuộc batdongsan. Gán chung vào "Khác" sẽ tạo một nhóm lớn lẫn nhiều loại nhà.
2. Trùng (giá, diện tích, quận, loại hình)	989	8,32	Cùng một căn được đăng lại; nếu giữ, bản sao rơi vào cả train và test.
3. Ngoại lai đơn giá	420	3,53	Ngoài 15–450 triệu/m ² hoặc ngoài 1,5×IQR tính riêng trong từng quận.
4. Diện tích ngoài 15–500 m ²	7	0,06	Ngoài dải nhà ở đô thị.
5. Sai số dự đoán thử APE > 50%	227	1,91	Tin mà mô hình thử dự đoán lệch trên 50%, xem là tin ảo hoặc sai lệch (chi tiết bên dưới).
Tổng loại	4.452	37,45	
Giữ lại (df_clean)	7.436	62,55	

Về bước 5. Nhóm huấn luyện thử Random Forest trên log(giá) với 80% trong 7.663 tin còn lại sau bước 4 (train_test_split, random_state=42), dự đoán 20% còn lại và loại tin có |dự đoán – giá| / giá > 50%. Danh sách 227 URL được lưu tại data/interim/loai_ape_lan_chay_goc.csv để tái lập đúng tập 7.436 dòng. Hàm tai_tao_buoc_ape() chạy lại bước này và đánh dấu 224 tin, trùng 222/227 với danh sách gốc (lần chạy gốc không lưu phiên bản thư viện nên không khớp tuyệt đối).

Lưu ý cho Bài tập 4: cả 227 tin đều thuộc phần test của phép chia random_state=42. Nếu BT4 dùng lại đúng phép chia này, tập test đã bị bỏ bớt tin khó đoán nên điểm sẽ cao hơn thực tế. Nhóm sẽ đánh giá bằng cross-validation và báo cáo thêm kết quả trên 7.663 dòng trước bước 5.

4.2. Chuẩn hóa nhãn loại hình

Trên 9.079 dòng có nhãn: "Nhà riêng" → Nhà riêng; "căn hộ" → Căn hộ; Nhà phố, Nhà mặt tiền, Đất, Biệt thự, Shophouse giữ tên; "Kho - Nhà xưởng" (8), "Bán nhà hàng - Khách sạn" (3), "Nhà hàng - Khách sạn" (2) → Khác (13 dòng, còn 7 sau các bước lọc). Nếu xuất hiện nhãn ngoài bảng ánh xạ, code dừng với thông báo lỗi.

5. Đánh giá chất lượng dữ liệu

5.1. Giá trị thiếu

- **Thô – CafeLand:** thiếu giá 393 tin (3,98%), thiếu diện tích 1.224 tin (12,38%), thiếu loại hình 421 tin (4,26%); 490 tin ghi giá "Thương lượng" (không quy đổi được thành số).
- **Thô – batdongsan:** thiếu loại hình 8.355 tin (27,71%), trong đó 7.847 tin ở TP.HCM. Các cột khác gần như đủ.
- **Cả hai nguồn không có cột quận/huyện** → quận được trích từ mô tả; tin không trích được bị loại khi tạo df_raw.
- **df_raw:** chỉ còn loai_hinh trống 2.809 dòng (23,63%). **df_clean:** 0 ô trống.
- **Cách điền ở df_clean:** số phòng ngủ → trung vị theo loại nhà (kèm co_tt_phong_ngu); số WC → theo số phòng ngủ; số tầng không nêu → 1; mặt tiền, hẻm → -1 (kèm co_tt_mat_tien); phường, đường → Khong_ro.

5.2. Trùng lặp và khóa chính

Ba file thô không có dòng trùng và không trùng URL. url duy nhất 100% ở df_raw và df_clean. Khi tạo df_raw, 267 tin trùng chéo nguồn (khóa: tiêu đề chuẩn hóa + diện tích + giá làm tròn) đã bị loại; ở df_clean loại thêm 989 tin trùng theo 4 cột (mục 4.1).

5.3. Kiểu dữ liệu chưa nhất quán

- Giá và diện tích trên web là chuỗi ("4 tỷ 480 triệu", "74,8m2", "77 m2", "Thương lượng") → đã quy đổi về triệu VNĐ và m².
- Nhãn loại hình viết lệch ("Nhà riêng", "căn hộ") → chuẩn hóa ở df_clean.
- bat_dong_san_raw.xls và chotot_bds_dataset.xls không phải Excel thật → đọc bằng pd.read_csv.
- Ngày đăng hai sàn viết khác nhau và không được giữ lại → dữ liệu là lát cắt.

5.4. Ngoại lai

Khi tạo df_raw: ngưỡng cứng (giá 100 triệu–200 tỷ, diện tích 10–10.000 m²) và IQR×3 trên toàn bộ. Ở df_clean: lọc đơn giá hai tầng (mục 4.1). Dải cuối: giá 340 triệu–44 tỷ, diện tích 15–270 m². Vẫn còn tin bất thường theo từng nhóm, ví dụ 10 căn hộ giá trên 30 tỷ → xử lý ở BT3.

5.5. Vì sao không gộp Chợ Tốt

chotot_bds_dataset.xls (5.000 tin) chỉ có 3.889 tin TP.HCM, 1.460 tin có chữ "cho thuê", 937 tin phòng trọ; cột area bị lỗi khi cào. CafeLand + batdongsan đã đủ số dòng, nên Chợ Tốt được giữ làm bằng chứng cho phương án dự phòng và cấu hình loại khỏi pipeline (config.yaml → nguồn_su_dung).

6. Mười vấn đề còn mở cho Bài tập 3

#	Vấn đề	Bằng chứng	Rủi ro	Việc làm ở BT3
1	Giá, diện tích lệch phải	Độ lệch 1,76 và 1,46; sau log còn 0,09 và 0,05	Hồi quy tuyến tính bị tin đắt kéo lệch	Histogram + KDE trước/sau log
2	Ngoại lai theo nhóm	10 căn hộ > 30 tỷ; đơn giá Quận 5 gấp 4,5 lần Hóc Môn	Một ngưỡng chung cắt sai	Boxplot theo loại nhà × quận
3	Cột quy mô đi cùng nhau	WC–phòng ngủ 0,73; mat_do_xay–số tầng 0,70	Không tách được tác động riêng	Heatmap tương quan, VIF
4	Thiếu phường, đường	Khong_ro 67,25% và 38,78%; 785 phường chỉ là số	One-hot nổ chiều, trùng tên	Gom quận thành vùng; chỉ giữ đường phổ biến
5	Mặt tiền, hẻm đầy –1	78,31% và 88,19% là –1	Mô hình hiểu –1 là kích thước	Dùng kèm cờ đánh dấu; không scale –1
6	Hai sàn khác cơ cấu	Nhà riêng: CafeLand 68,0%, batdongsan 34,4%. Trung vị giá 8,3 tỷ vs 7,0 tỷ	Kết luận "giá thành phố" lẫn khác biệt nguồn	So sánh theo nguồn; đưa nguồn_du_lieu vào mô hình
7	Văn bản còn số	90,09% tiêu đề sạch còn chữ số	Mô hình văn bản học vệt giá	Rà n-gram, mở rộng regex giá
8	Cờ hẻm và mặt tiền mâu thuẫn	1.078 tin (14,50%) cùng lúc là 1	Thuộc tính vị trí kém tin cậy	Đọc mẫu, đặt quy tắc ưu tiên
9	Bước lọc APE	227 tin bị loại đều nằm trong phần test của phép chia random_state=42	Thiên lệch chọn mẫu; điểm BT4 cao giả	Xem 227 tin tập trung ở đâu; BT4 dùng CV và báo cáo thêm trên 7.663 dòng
10	Không có ngày đăng	batdongsan có tin 2024–2026; CafeLand chủ yếu 2026	Biến động theo thời gian lẫn vào lệch nguồn	Không suy diễn xu hướng

7. Hạn chế và cách tái lập

- Giá là giá chào bán trên tin đăng, không phải giá giao dịch. Mọi dự đoán là giá chào bán tham chiếu.
- Thiếu Củ Chi, Bình Chánh, Cần Giờ; vùng ven chỉ có Hóc Môn và Nhà Bè.
- Cờ 0/1 phản ánh nội dung người đăng viết, chưa kiểm chứng thực địa.
- Mô tả có thể còn tên và số điện thoại dính chữ; không đưa ra thành cột.

Tái lập (từ thư mục gốc dự án, Python 3.11+, pandas 2.2):

- python -m src.data.lam_sach_du_lieu → data/interim/df_raw_chay_lai.csv (bản chạy lại để đối chiếu, không ghi đè df_raw.csv đã chốt)

- `python -m src.features.tao_dac_trung → data/processed/df_clean.csv` (đọc `df_raw.csv` + danh sách APE; ra đúng 7.436 dòng)
- Khử trùng theo 4 cột có thể gộp nhằm vài căn khác nhau nhưng trùng giá, diện tích, quận, loại hình.

Ghi chú sử dụng AI: Claude (Anthropic) hỗ trợ rà soát tính tái lập, đóng gói hàm trong `src/`, đối chiếu số liệu giữa notebook và tài liệu này, tái tạo bước lọc APE để kiểm chứng. Nhóm kiểm tra lại và giải thích được toàn bộ logic xử lý.