

TỪ ĐIỂN DỮ LIỆU (DATA DICTIONARY)

Nhóm thực hiện	Nhóm 7 và 8 (Tuần 4–9 / 2026)
Giai đoạn học phần	Ask & Acquire
Tập sạch lần 1	df_raw.csv (11.888 dòng × 10 cột)
Tập sạch lần 2	df_clean.csv (7.436 dòng × 27 cột)
Nguồn thô ban đầu	cafeland_raw.csv (9.883 × 9) và bat_dong_san_raw.xls (30.149 × 9)
Sáu thành viên	1. Trần Thị Ngọc Ánh (24639511) 2. Nguyễn Bá Công (24689091) 3. Hà Trọng Hữu Duy (24702061) 4. Lê Anh Duy (24681951) 5. Nguyễn Thị Trâm (24689661) 6. Văn Tường Vy (24648771)

1. TỔNG QUAN DÒNG DỮ LIỆU VÀ HAI TẬP ĐÃ LÀM SẠCH

Cả hai tệp df_raw.csv và df_clean.csv đều là tập dữ liệu chính đã làm sạch (không còn ô trống hình thức, không có dòng trùng lặp tuyệt đối, khóa URL duy nhất 100%) từ hai nguồn thô cào trên web. Hai tệp đại diện cho hai mức độ xử lý kế tiếp nhau trong pipeline dữ liệu, không phải một tệp thô và một tệp sạch:

- Dữ liệu thô cào từ web.** Hai tệp tin cào tự động: cafeland_raw.csv (9.883 tin × 9 cột; 9,58 MB) và bat_dong_san_raw.xls (30.149 tin × 9 cột; 51,30 MB; phần mở rộng .xls nhưng định dạng văn bản đọc bằng pd.read_csv với bảng mã utf-8-sig). Dữ liệu giá và diện tích ở dạng văn bản (“3 tỷ 150 triệu”, “74,8m2”, “Thương lượng”). CafeLand thiếu giá 3,98% và thiếu diện tích 12,38%. Batdongsan thiếu loại hình 27,71% (8.355 tin, trong đó 7.847 tin thuộc TP.HCM). Có nhiều tin giá ảo cực đoan (tới 999 tỷ) và diện tích ảo.
- Lần chuẩn hóa thứ nhất – df_raw.csv (11.888 dòng × 10 cột).** Nhóm gộp hai sàn, chỉ giữ tin tại TP.HCM, quy đổi giá thành số thực triệu đồng, quy đổi diện tích thành mét vuông, loại tin thiếu giá hoặc diện tích và tin “thỏa thuận”, gắn nhãn nguồn dữ liệu. Tập này đạt 0 dòng trùng tuyệt đối, mã tin (url) duy nhất 11.888/11.888 tin (100%). Tập này lưu giữ các thuộc tính cốt lõi của tin đăng để mô tả mặt bằng tổng thể và đối chiếu hai nguồn.
- Tạo đặc trưng từ tiêu đề và mô tả – df_clean.csv (7.436 dòng × 27 cột).** Lấy từ các tin của df_raw, chuẩn hóa loại nhà thành 8 nhóm, lọc bỏ các tin thiếu nhãn loại hình và các tin ngoại lai cực đoan hai tầng, khử trùng lặp cấu trúc chéo môi giới, sau đó bóc tách 17 đặc trưng mới từ tiêu đề và mô tả (số phòng ngủ, số tầng, số vệ sinh, kích thước mặt tiền, hẻm, 7 đặc điểm nhà 0/1, diện tích sàn ước lượng, tiêu đề và mô tả đã che cụm số giá). Bỏ cột tỉnh_thanh vì toàn bộ đều là TP. Hồ Chí Minh. Bỏ cột đơn giá đã tính sẵn để tránh rò rỉ nhãn mục tiêu. Tập 7.436 dòng là dữ liệu trọng tâm cho trực quan hóa khám phá (Bài tập 3) và huấn luyện học máy (Bài tập 4).

Nhóm dữ liệu	Tệp dữ liệu	Định dạng	Dung lượng	Quy mô	Bản chất xử lý
Nguồn thô	cafeland_raw.csv	CSV UTF-8	9,58 MB	9.883 dòng × 9 cột	Cào gốc nguồn chính; dữ liệu dạng chuỗi chữ thô
Nguồn thô	bat_dong_san_raw.xls	CSV utf-8-sig	51,30 MB	30.149 dòng × 9 cột	Cào gốc nguồn phụ; dữ liệu dạng chuỗi chữ thô
Đã làm sạch lần 1	df_raw.csv	CSV UTF-8	17,24 MB	11.888 dòng × 10 cột	Chuẩn hóa kiểu số, đơn vị, phạm vi địa bàn TP.HCM
Đã làm sạch lần 2	df_clean.csv	CSV UTF-8	11,05 MB	7.436 dòng × 27 cột	Bóc tách 17 đặc trưng từ văn bản, lọc ngoại lai 2 tầng

Yêu cầu tối thiểu của đề cương học phần là tập dữ liệu phải có ít nhất 5.000 dòng và ít nhất 8 biến. Tập df_raw.csv có 11.888 dòng và 10 biến; tập df_clean.csv có 7.436 dòng và 27 biến. Cả hai tập đều vượt xa điều kiện tối thiểu. Mọi dòng tin đều ghi rõ nguồn gốc (cafeland hoặc batdongsan) và bảo toàn đường dẫn gốc (url) phục vụ truy xuất nguồn gốc.

Về thời điểm thu thập: Nguồn CafeLand có 9.461/9.883 dòng tin hiển thị ngày đăng trong năm 2026. Nguồn Batdongsan có các tin trải từ năm 2024, 2025 đến 2026. Project Charter xác định “tin đăng còn hiệu lực tại thời điểm khảo sát cuối tháng 8 – đầu tháng 9/2026”. Do hai tệp đã làm sạch không lưu giữ cột ngày đăng, dữ liệu được xem xét dưới dạng một lát cắt ngang (cross-sectional snapshot). Vấn đề sai lệch mốc thời gian giữa hai sàn được ghi nhận cụ thể tại Mục 6.10.

2. TỪ ĐIỂN DỮ LIỆU ĐÃ LÀM SẠCH LẦN 1 (df_raw.csv – 10 BIẾN)

df_raw.csv là tập dữ liệu chuẩn hóa cấp độ 1: đồng nhất kiểu số và đơn vị, giới hạn địa bàn TP.HCM, đảm bảo mã tin duy nhất, gắn nhãn nguồn dữ liệu minh bạch. Phân bố nguồn: batdongsan 8.374 tin (70,44%), cafeland 3.514 tin (29,56%). Tên cột đặt theo chuẩn snake_case tiếng Việt không dấu. Tập này phục vụ mô tả thống kê thị trường tổng thể và đối chiếu hai nguồn trước khi mở rộng đặc trưng.

STT	Tên biến	Kiểu dữ liệu	Đơn vị	Ý nghĩa và khoảng giá trị thực tế	Vai trò trong đồ án
1	tieu_de	object	văn bản	Tiêu đề tin đăng bán bất động sản. 11.886 tiêu đề khác nhau (có 2 cặp trùng tiêu đề nhưng khác hoàn toàn về URL và nội dung mô tả chi tiết).	Đầu vào để trích xuất đặc trưng từ văn bản ở df_clean. Không dùng thô làm biến số.
2	gia_ban	float64	triệu VNĐ	Giá niêm yết đã quy đổi sang số thực. Nhỏ nhất 109 triệu; trung vị 6.990 triệu (6,99 tỷ); trung bình 9.568,22 triệu; lớn nhất 44.000 triệu (44 tỷ). Độ lệch phải 1,89.	Biến mục tiêu cần dự đoán (Target). Ở df_clean được lọc chặn sàn 340 triệu và biến đổi thêm log_gia_ban.
3	dien_tich_m2	float64	m²	Diện tích đất hoặc căn hộ theo tin đăng, quy đổi sang mét vuông. Nhỏ nhất 10 m²; trung vị 70 m²; trung bình 81,01 m²; lớn nhất 270 m². Độ lệch 1,53.	Biến giải thích cốt lõi. Ở df_clean được lọc chặn sàn 15 m² và biến đổi thêm log_dien_tich.
4	tinh_thanh	object	danh mục	Tỉnh/thành phố trực thuộc trung ương. 100% là “TP. Hồ Chí Minh” (11.888 dòng).	Xác định đúng phạm vi địa lý nghiên cứu. Bỏ ở df_clean vì toàn bộ mẫu có giá trị đồng nhất (zero variance).
5	quan_huyen	object	danh mục	Quận hoặc huyện tại TP.HCM. Gồm 20 đơn vị hành chính. Nhiều tin nhất: Quận 12 (1.281), Quận 7 (928), Quận 1 (909), Gò Vấp (908), Bình Tân (877). Ít tin nhất: Huyện Nhà Bè (130), Quận 5 (145), Quận 11 (242). Mẫu không có Củ Chi, Bình Chánh, Cần Giờ.	Biến phân vùng địa lý giải quyết câu hỏi nghiên cứu phụ về chênh lệch định giá khu vực. Kế thừa sang df_clean.
6	mo_ta_dac_diem	object	văn bản	Nội dung mô tả chi tiết đặc điểm bất động sản. Có 11.874 mô tả khác nhau; 14 mô tả trùng nhau (do môi giới đăng lại cùng một căn).	Nguồn văn bản chủ lực để bóc tách số phòng, số tầng, mặt tiền, hẻm và các tiện ích ở df_clean.
7	loai_hinh	object	danh mục	Loại hình bất động sản gom sơ bộ từ nguồn thô: 10 nhãn danh mục và 2.809 dòng để trống từ nguồn batdongsan. Nhãn phổ biến: “Nhà riêng” (4.273), “căn hộ” (1.222), “Nhà phố” (1.181). Ba nhóm đuôi không quá 8 tin.	Ở df_clean, nhóm lọc bỏ 2.809 dòng khuyết, sửa lỗi chính tả và quy hoạch chuẩn hóa thành 8 nhóm.
8	nguồn_du_lieu	object	danh mục	Sản giao dịch gốc của tin đăng: batdongsan có 8.374 tin (70,44%); cafeland có 3.514 tin (29,56%).	Phục vụ đối chiếu đa nguồn (Tiêu chí 1). Giữ lại để kiểm định sự sai lệch phân bố giữa hai nguồn.
9	url	object	đường dẫn	Đường dẫn URL gốc của tin đăng trên website. 11.888/11.888 mã duy nhất (100%).	Khóa chính dùng để truy vết và kiểm soát trùng lặp. Không đưa vào mô hình học máy.
10	gia_moi_m2_trieu	float64	triệu VNĐ/m²	Đơn giá = giá bán ÷ diện tích. Nhỏ nhất 1,18; trung vị 107,69; trung bình 126,53; lớn nhất 2.500 triệu/m². Độ lệch phải 4,39.	Đơn giá tham chiếu. Bắt buộc loại bỏ ở df_clean khi dự đoán giá bán vì chứa trực tiếp nhãn mục tiêu (leakage).

2.1. Nhãn loại hình chưa thống nhất trong df_raw

Trong df_raw.csv, biến loai_hinh vẫn còn tồn tại các nhược điểm từ dữ liệu gốc cào trên mạng: có 2.809 dòng từ batdongsan chưa được gán nhãn loại hình (để trống); cùng một loại nhà nhưng được ghi khác nhau: “Nhà riêng” thiếu dấu

tiếng Việt, “căn hộ” viết chữ thường. Ngoài ra, có 3 nhóm quá nhỏ: Kho – Nhà xưởng (8 tin), Bán nhà hàng – Khách sạn (3 tin), Nhà hàng – Khách sạn (2 tin). Các nhóm quá nhỏ này không đủ cỡ mẫu đại diện để huấn luyện thuật toán. Toàn bộ quy tắc chuẩn hóa sang 8 nhóm đồng nhất ở df_clean được trình bày chi tiết tại Mục 4.2.

3. TỪ ĐIỂN DỮ LIỆU ĐÃ LÀM SẠCH LẦN 2 (DF_CLEAN.CSV – 27 BIẾN)

df_clean.csv được kế thừa từ df_raw, trải qua quá trình làm sạch sâu hai tầng và trích xuất thêm 17 đặc trưng từ tiêu đề và mô tả, phục vụ trực quan hóa dữ liệu (Bài tập 3) và xây dựng mô hình dự đoán giá (Bài tập 4). Tập dữ liệu gồm 7.436 dòng (chiếm 62,55% số tin của df_raw). Nguồn: batdongsan 4.400 tin (59,17%), cafeland 3.036 tin (40,83%). Toàn bộ 27 cột đạt 0% ô trống hình thức. Cần lưu ý: “không trống ô” không có nghĩa là mọi tin đều đủ thông tin ngoài đời: hai cột kích thước ghi -1 khi văn bản không nêu số đo; hai cột địa chỉ ghi Khong_ro khi không trích xuất được tên — đây là các dấu hiệu khuyết thiếu có kiểm soát, không phải giá trị vật lý.

STT	Tên biến	Nhóm đặc trưng	Kiểu	Đơn vị	Mô tả ý nghĩa, khoảng giá trị và lưu ý sử dụng
1	gia_ban	Giá bán	float64	triệu VNĐ	Giá niêm yết sau lọc ngoại lai. Nhỏ nhất 340 triệu; trung vị 7.500 triệu (7,5 tỷ); trung bình 9.970,76 triệu; lớn nhất 44.000 triệu. Độ lệch phải 1,76. Biến mục tiêu cần dự đoán.
2	log_gia_ban	Giá bán	float64	ln(triệu)	Logarit tự nhiên của giá bán. Nhỏ nhất 5,83; trung vị 8,92; lớn nhất 10,69. Độ lệch 0,09 — phân phối gần đối xứng chuẩn. Giúp tuyến tính hóa mô hình hồi quy và giảm sai số dự báo.
3	dien_tich_m2	Diện tích	float64	m²	Diện tích sau khi lọc sàn 15 m² và trần 500 m². Nhỏ nhất 15 m²; trung vị 72 m²; trung bình 84,75 m²; lớn nhất 270 m². Độ lệch 1,46.
4	log_dien_tich	Diện tích	float64	ln(m²)	Logarit tự nhiên của diện tích. Nhỏ nhất 2,71; trung vị 4,28; lớn nhất 5,60. Độ lệch 0,05. Phù hợp cho các thuật toán yêu cầu phân phối chuẩn.
5	quan_huyen	Vị trí	object	danh mục	20 quận/huyện TP.HCM. Nhiều tin nhất: Quận 12 (682), Quận 1 (606), Quận 7 (600), Gò Vấp (581), TP. Thủ Đức (524). Ít tin nhất: Huyện Nhà Bè (71), Quận 5 (89), Quận 4 (127).
6	phuong	Vị trí	object	danh mục	Phường/xã bóc tách từ tiêu đề/mô tả. 347 giá trị. Khong_ro chiếm 5.001 dòng (67,25%). 785 dòng chỉ ghi số (“7”, “12”...) — dễ trùng lặp giữa các quận nếu không ghép kèm tên quận.
7	ten_duong	Vị trí	object	danh mục	Tên đường bóc tách sau từ khóa “đường/phố”. 1.332 giá trị. Khong_ro chiếm 2.884 dòng (38,78%). Tuyến đường phổ biến: Huỳnh Tấn Phát (108), Quang Trung (82), Phạm Thế Hiển (66).
8	loai_hinh	Loại hình	object	danh mục	8 nhóm sau chuẩn hóa: Nhà riêng 3.580 (48,14%); Nhà phố 970 (13,04%); Căn hộ 949 (12,76%); Nhà mặt tiền 801 (10,77%); Đất 680 (9,14%); Biệt thự 425 (5,72%); Shophouse 24 (0,32%); Khác 7 (0,09%).
9	so_phong_ngu	Quy mô	float64	phòng	Số phòng ngủ bóc tách từ văn bản. Khi thiếu được điền bằng trung vị theo từng loại hình. Nhỏ nhất 1; trung vị 3; trung bình 3,47; lớn nhất 10. 26,22% số dòng là giá trị điền thay (xem co_tt_phong_ngu).
10	so_tang	Quy mô	float64	tầng	Số tầng/lầu bóc tách từ văn bản. Căn hộ và đất mặc định là 1. Nhỏ nhất 1; trung vị 2; trung bình 2,58; lớn nhất 8 tầng.
11	so_wc	Quy mô	float64	phòng	Số phòng vệ sinh bóc tách từ văn bản. Khi thiếu được điền suy diễn theo số phòng ngủ. Nhỏ nhất 1; trung vị 3; trung bình 3,18; lớn nhất 8. Tương quan mạnh với số phòng ngủ.
12	mat_tien_m	Kích thước	float64	mét	Chiều rộng mặt tiền bóc tách từ văn bản. Nếu không có số liệu ghi -1 (5.823 dòng, 78,31%). Với 1.613 tin có số liệu: nhỏ nhất 2,3 m; trung vị 5,0 m; lớn nhất 30 m. Không tính trung bình toàn cột.

13	rong_hem_m	Kích thước	float64	mét	Độ rộng hèm bóc tách từ văn bản. Nếu không có số liệu ghi -1 (6.558 dòng, 88,19%). Với 878 tin có số liệu: nhỏ nhất 2 m; trung vị 6 m; lớn nhất 15 m. Không tính trung bình toàn cột.
14	mat_do_xay	Quy mô	float64	m ² sàn ước lượng	Diện tích × số tầng (ước tính tổng diện tích sàn xây dựng). Nhỏ nhất 15; trung vị 159; trung bình 216,36; lớn nhất 2.080 m ² . Không đưa đồng thời cùng diện tích và số tầng vào hồi quy.
15	la_hem	Đặc điểm nhà	int64	0 hoặc 1	Bảng 1 khi tiêu đề/mô tả chứa từ khóa hèm, ngõ, kiệt, hèm xe tải, hèm xe hơi. Có: 3.150 tin (42,36%). Thể hiện thông tin người bán đăng, không phải số liệu đo đạc thực địa.
16	la_mat_tien	Đặc điểm nhà	int64	0 hoặc 1	Bảng 1 khi chứa từ khóa mặt tiền, mặt phố, mặt tiền đường. Có: 3.322 tin (44,67%). Có 1.078 tin vừa có cờ hèm vừa có cờ mặt tiền (14,50%) — mâu thuẫn ngữ nghĩa được phân tích ở Mục 6.8.
17	co_so_hong	Đặc điểm nhà	int64	0 hoặc 1	Bảng 1 khi chứa từ khóa sổ hồng, sổ đỏ, hoàn công, pháp lý chuẩn. Có: 4.180 tin (56,21%). Yếu tố pháp lý quan trọng tác động tới giá bán.
18	co_noi_that	Đặc điểm nhà	int64	0 hoặc 1	Bảng 1 khi chứa từ khóa full nội thất, đầy đủ nội thất, tặng nội thất. Có: 1.289 tin (17,33%).
19	oto_vao	Đặc điểm nhà	int64	0 hoặc 1	Bảng 1 khi chứa từ khóa ô tô đỗ cửa, xe hơi vào nhà, hèm xe tải. Có: 2.570 tin (34,56%). Gia tăng đáng kể giá trị bất động sản trong hèm.
20	gan_truong_cho	Đặc điểm nhà	int64	0 hoặc 1	Bảng 1 khi chứa từ khóa gần chợ, gần trường, bệnh viện, siêu thị. Có: 3.473 tin (46,71%). Từ khóa quảng bá tiện ích xung quanh.
21	chinh_chu	Đặc điểm nhà	int64	0 hoặc 1	Bảng 1 khi chứa từ khóa chính chủ gửi bán, kẹt tiền chính chủ. Có: 2.115 tin (28,44%). Thường mang tính từ khóa thu hút người mua.
22	co_tt_phong_ngu	Đánh dấu khuyết	int64	0 hoặc 1	Bảng 1 nếu tin gốc có thông tin số phòng ngủ (5.486 tin, 73,78%). Bảng 0 nếu so_phong_ngu là giá trị điền thay (1.950 tin, 26,22%). Giúp mô hình phân biệt dữ liệu thực và giá trị suy đoán.
23	co_tt_mat_tien	Đánh dấu khuyết	int64	0 hoặc 1	Bảng 1 nếu mat_tien_m > 0 (1.613 tin, 21,69%). Bảng 0 nếu mat_tien_m = -1 (5.823 tin, 78,31%). Phải sử dụng kèm theo biến mat_tien_m.
24	nguồn_du_lieu	Nguồn tin	object	danh mục	Sản giao dịch gốc: batdongsan 4.400 tin (59,17%); cafeland 3.036 tin (40,83%). Dùng để kiểm soát hiệu ứng nguồn tin trong mô hình định giá.
25	tieu_de_sach	Văn bản	object	văn bản	Tiêu đề đã che các cụm số giá và diện tích bằng ký hiệu <SO>. Có 7.368 tiêu đề khác nhau. 6.699 dòng (90,09%) vẫn còn chứa các chữ số dính chữ (ví dụ 2PN, 4x15m).
26	mo_ta_sach	Văn bản	object	văn bản	Mô tả đã che cụm số giá và diện tích bằng ký hiệu <SO>. Có 7.432 mô tả khác nhau. Hầu hết các dòng vẫn còn chứa chữ số dính chữ. Dùng khai phá từ khóa, không nạp thô vào mô hình giá.
27	url	Mã tin	object	đường dẫn	Địa chỉ URL tin gốc. 7.436/7.436 giá trị duy nhất (100%). Toàn bộ URL của df_clean đều nằm trong df_raw.

3.1. Phân tích phân phối các biến số

Đối với giá bán: trung vị là 7.500 triệu (7,5 tỷ) trong khi giá trung bình lên tới 9.970,76 triệu do bị kéo bởi các bất động sản giá trị cao (lớn nhất 44 tỷ). Độ lệch phải 1,76 khẳng định phân phối lệch mạnh, do đó việc bổ sung biến `log_gia_ban` (độ lệch giảm xuống 0,09) là giải pháp bắt buộc để tối ưu hồi quy. Đối với mặt tiền và hèm: phần lớn dữ liệu bị khuyết nên ghi -1 (chiếm lần lượt 78,31% và 88,19%); tuyệt đối không tính toán hay diễn giải giá trị trung bình trên toàn cột như một số đo thực tế.

3.2. Phân tích loại hình bất động sản và đơn giá theo quận

Chỉ số đơn giá (triệu VNĐ/m² = giá bán ÷ diện tích) được tính toán riêng trong báo cáo để phân tích thị trường, không lưu trữ trong df_clean nhằm ngăn ngừa rò rỉ thông tin nhân mục tiêu trong học máy. Bảng dưới đây thống kê số lượng tin đăng, tỉ trọng và các giá trị trung vị theo 8 loại hình bất động sản:

Loại hình	Số tin đăng	Tỉ lệ (%)	Trung vị giá bán (triệu VNĐ)	Trung vị diện tích (m ²)	Trung vị đơn giá (triệu VNĐ/m ²)
Nhà riêng	3.580	48,14	7.225	65	118,14
Nhà phố	970	13,04	6.985	64	115,05
Căn hộ	949	12,76	6.000	70	78,43
Nhà mặt tiền	801	10,77	10.500	88	121,17
Đất	680	9,14	6.200	100	68,07
Biệt thự	425	5,72	14.000	126	115,38
Shophouse	24	0,32	7.500	102	62,05
Khác	7	0,09	16.800	160	85,71

Quận/huyện	Số tin đăng	Trung vị đơn giá (triệu VNĐ/m ²)	Quận/huyện	Số tin đăng	Trung vị đơn giá (triệu VNĐ/m ²)
Quận 5	89	208,1	Quận Gò Vấp	581	119,8
Quận 3	246	196,6	Quận 8	436	112,7
Quận 10	254	181,6	Quận Tân Phú	522	109,2
Quận 1	606	175,7	Quận 6	207	103,4
Quận 11	163	140,6	Quận Bình Tân	514	88,8
Quận Bình Thạnh	460	136,9	Quận 9	357	80,0
Quận Tân Bình	456	135,4	Quận 12	682	75,0
Quận 4	127	121,9	Huyện Nhà Bè	71	74,3
Quận 2	368	121,9	TP. Thủ Đức	524	72,2
Quận 7	600	121,9	Huyện Hóc Môn	173	46,0

4. QUY TRÌNH CHUYỂN ĐỔI TỪ DF_RAW SANG DF_CLEAN

STT	Cột ở df_raw.csv	Cột tương ứng ở df_clean.csv	Quy tắc xử lý và kỹ nghệ đặc trưng
1	tieu_de	tieu_de_sach	Chuyển chữ thường, thay thế các cụm số giá và diện tích bằng ký hiệu <SO> nhằm ngăn chặn mô hình ghi nhớ máy móc con số trong văn bản.
2	gia_ban	gia_ban và log_gia_ban	Lọc chặn sàn giá 340 triệu; tạo thêm biến logarit tự nhiên log_gia_ban nhằm thu hẹp đuôi dài của bất động sản giá cao.
3	dien_tich_m2	dien_tich_m2 và log_dien_tich	Lọc chặn sàn diện tích 15 m ² và trần 500 m ² ; tạo thêm biến logarit tự nhiên log_dien_tich.
4	tin_thanh	(loại bỏ)	Toàn bộ 100% dòng dữ liệu đều là TP. Hồ Chí Minh — cột đơn giá trị (zero variance), không mang giá trị phân biệt cho thuật toán.
5	quan_huyen	quan_huyen	Giữ nguyên 20 quận/huyện phân vùng địa lý.
6	mo_ta_dac_diem	17 cột trích xuất từ văn bản + mo_ta_sach	Trích xuất số phòng ngủ, số tầng, số vệ sinh, kích thước mặt tiền, hẻm, 7 đặc điểm nhà 0/1; che các cụm số để tạo mo_ta_sach.
7	loai_hinh	loai_hinh	Sửa lỗi chính tả “Nhà riêng” thành “Nhà riêng”, “căn hộ” thành “Căn hộ”; gom các phân khúc quá nhỏ vào nhóm “Khác” (quy hoạch từ 10 nhân còn 8 nhóm). Loại bỏ các tin để trống nhãn.

8	nguồn_du_lieu	nguồn_du_lieu	Giữ nguyên nhãn nguồn để phân tích và kiểm soát sai lệch giữa hai sàn giao dịch.
9	url	url	Giữ nguyên làm khóa chính phục vụ kiểm tra chéo và bảo toàn tính truy vết dữ liệu.
10	gia_moi_m2_trieu	(loại bỏ)	Do đơn giá = giá bán ÷ diện tích, nếu đưa vào mô hình dự đoán giá bán sẽ gây rò rỉ nhãn mục tiêu tuyệt đối (data leakage). Bắt buộc loại bỏ.

4.1. Kiểm toán minh bạch 4.452 dòng bị loại từ df_raw sang df_clean

Toàn bộ 7.436 mã URL của df_clean đều nằm trong df_raw (100% là tập con). Có 4.452 dòng tin (chiếm 37,45% tổng số tin của df_raw) đã được xử lý loại bỏ trong notebook làm sạch số 2 (02_lam_sach_du_lieu_2.ipynb). Quá trình kiểm toán kỹ thuật đối chiếu chính xác 100% nguyên nhân loại bỏ như sau:

Tầng lọc kỹ thuật trong notebook làm sạch 2	Số dòng loại	Tỉ lệ (%)	Cơ sở kỹ thuật và ý nghĩa phương pháp
1. Lọc bỏ tin thiếu loại hình bất động sản	2.809	23,63%	Toàn bộ 2.809 dòng này thuộc nguồn batdongsan.vn cáo về bị khuyết nhãn. Việc gán bù nhãn sẽ gây sai lệch phân tầng định giá nghiêm trọng.
2. Khử trùng lặp cấu trúc chéo môi giới	989	8,32%	Khử trùng lặp trên bộ 4 khóa: [giá bán, diện tích, quận/huyện, loại hình]. Cùng một căn nhà được nhiều môi giới đăng lại gây sai số phương sai.
3. Lọc ngoại lai đơn giá 2 tầng (chặn cứng & IQR theo quận)	420	3,53%	Loại đơn giá ngoài khoảng 15–450 triệu/m ² hoặc vượt ngoài khoảng 1.5×IQR tính riêng cho từng quận/huyện (tránh cắt nhầm nhà trung tâm).
4. Lọc diện tích nằm ngoài giới hạn nhà ở đô thị	7	0,06%	Loại bỏ các tin có diện tích nhỏ hơn 15 m ² hoặc lớn hơn 500 m ² (không thuộc dải nhà ở đô thị thông thường).
5. Lọc phần dư bất thường từ mô hình baseline	227	1,91%	Loại bỏ các tin có sai số tuyệt đối phần trăm (APE > 50%) từ mô hình thử nghiệm ban đầu (phát hiện tin ảo, sai lệch dữ liệu ngầm).
Tổng số dòng loại khỏi df_raw.csv	4.452	37,45%	Giải trình đầy đủ 100% số dòng loại, hoàn toàn ăn khớp với mã nguồn thực thi.
Số dòng giữ lại trong df_clean.csv	7.436	62,55%	Bộ dữ liệu sạch hoàn chỉnh sẵn sàng cho trực quan hóa EDA và huấn luyện mô hình.

4.2. Chuẩn hóa nhãn loại hình bất động sản

Trên 7.436 dòng giữ lại của df_clean, các nhãn được quy đổi chặt chẽ: “Nhà riêng” (4.273 tin cũ) → “Nhà riêng”; “căn hộ” (1.222 tin cũ) → “Căn hộ”; các nhóm “Nhà phố”, “Nhà mặt tiền”, “Đất”, “Biệt thự”, “Shophouse” giữ nguyên tên chuẩn. Các tin thuộc nhóm “Bán nhà hàng – Khách sạn” và “Kho – Nhà xưởng” với số lượng rất nhỏ được gom vào nhóm “Khác” (gồm 7 tin) nhằm đảm bảo tính ổn định khi chạy mô hình học máy.

5. ĐÁNH GIÁ CHẤT LƯỢNG DỮ LIỆU BAN ĐẦU

Nhóm thực hiện kiểm toán chất lượng trên cả dữ liệu thô và hai tập dữ liệu đã làm sạch. Mục này đáp ứng trọn vẹn yêu cầu về “đánh giá tỉ lệ thiếu, số dòng trùng lặp, kiểu dữ liệu chưa nhất quán” của mức Đạt yêu cầu trong phiếu chấm.

5.1. Tỉ lệ khuyết thiếu (Missing Values)

Trên dữ liệu thô ban đầu: Nguồn CafeLand thiếu giá 3,98% (393 tin) và thiếu diện tích 12,38% (1.224 tin); có 487 tin ghi giá “Thương lượng”. Nguồn Batdongsan thiếu nhãn loại hình 27,71% (8.355 tin trên toàn quốc; trong đó 7.847 tin thuộc TP.HCM). Sau quá trình làm sạch: df_raw (11.888 dòng) đạt 0% ô trống ở 9/10 cột (chỉ còn 2.809 tin thiếu loại_hình chưa phân loại); df_clean (7.436 dòng) đạt 0,00% ô trống hình thức trên toàn bộ 27 cột thuộc tính.

Chiến lược kiểm soát thông tin khuyết thiếu ở df_clean: Thay vì điền trung bình một cách tùy tiện, nhóm áp dụng các quy tắc suy luận nghiệp vụ chuyên biệt: đối với số phòng ngủ và số vệ sinh, nhóm điền bằng trung vị theo từng loại hình nhà và tạo cột đánh dấu co_tt_phong_ngu; đối với mặt tiền và hẻm, nhóm ghi nhận mã -1 kèm theo cột đánh dấu co_tt_mat_tien để mô hình phân biệt rõ ràng giữa giá trị đo thực tế và tin khuyết thông tin; đối với phường và tên đường không bóc tách được, nhóm gán nhãn định danh Khong_ro.

5.2. Kiểm soát trùng lặp và tính toàn vẹn khóa chính

Khóa chính url đạt tính duy nhất tuyệt đối 100%: 11.888/11.888 mã ở df_raw và 7.436/7.436 mã ở df_clean. Cả hai tệp hoàn toàn không có dòng trùng lặp tuyệt đối. Ngoài ra, ở df_clean nhóm đã chủ động nhận diện và loại bỏ thêm 989 dòng trùng lặp cấu trúc chéo môi giới (những tin đăng trùng hoàn toàn về giá bán, diện tích, quận/huyện và loại hình), giúp ngăn chặn hiện tượng rò rỉ dữ liệu (data leakage) giữa tập huấn luyện và tập kiểm tra.

5.3. Xử lý kiểu dữ liệu không nhất quán

- Giá bán và diện tích trên web lưu dưới dạng chuỗi văn bản phức tạp, đan xen chữ và số (“11 tỷ 500 triệu”, “74,8 m2”, “Thương lượng”). Toàn bộ đã được phân tích bằng biểu thức chính quy (Regex) và quy đổi chuẩn xác thành số thực triệu VNĐ và mét vuông ở df_raw.
- Định dạng ngày đăng giữa hai sàn hoàn toàn khác biệt; cả hai tập làm sạch không lưu cột ngày, dữ liệu được chuẩn hóa thành một lát cắt tĩnh của thị trường bất động sản.
- Nhân loại hình bất động sản viết sai chính tả hoặc định dạng không chuẩn (“Nhà riêng”, “căn hộ”) đã được quy chuẩn hóa về 8 nhóm phân loại thống nhất.
- Tệp bat_dong_san_raw.xls thực chất là văn bản mã hóa UTF-8 với dấu phân cách tab/phẩy, đã được xử lý đúng bộ giải mã pd.read_csv(..., encoding='utf-8-sig').

5.4. Lọc ngoại lai và phạm vi dữ liệu hợp lệ

Các tin ảo có giá bán phi lý trên dữ liệu thô (tới 999 tỷ) và diện tích ảo đã bị loại bỏ khi tạo df_raw. Tại df_clean, nhóm tiếp tục áp dụng bộ lọc ngoại lai hai tầng nghiêm ngặt: lọc chặn cứng theo hiểu biết thị trường (đơn giá 15–450 triệu/m², diện tích 15–500 m², giá sàn 340 triệu) kết hợp chặn mềm 1.5×IQR tính riêng trong từng quận. Dải dữ liệu của df_clean gói gọn trong phạm vi bất động sản đô thị thực tế: giá bán từ 340 triệu đến 44 tỷ VNĐ, diện tích từ 15 m² đến 270 m².

6. MƯỜI VẤN ĐỀ CHẤT LƯỢNG CÒN MỎ CẦN XỬ LÝ Ở BƯỚC EDA TIẾP THEO

#	Vấn đề phát hiện ở Bài tập 2	Bằng chứng định lượng trên dữ liệu thực tế	Rủi ro phân tích nếu bỏ qua	Kế hoạch hành động cụ thể ở Bài tập 3 (EDA)
1	Phân phối giá bán và diện tích lệch phải mạnh	Độ lệch phải của giá bán là 1,76 (sau logarit còn 0,09); diện tích là 1,46 (sau log còn 0,05).	Mô hình hồi quy tuyến tính sẽ bị bóp méo hệ số bởi các bất động sản đắt tiền.	Vẽ biểu đồ histogram kết hợp KDE trước và sau logarit. Đánh giá tính chuẩn hóa và đối chiếu kết quả dự báo giữa gia_ban và log_gia_ban.
2	Ngoại lai phân tầng theo loại hình và quận/huyện	Mức giá 40–44 tỷ là bất thường đối với căn hộ chung cư nhưng hoàn toàn bình thường với biệt thự. Đơn giá Quận 5 (208,1 tr/m²) gấp 4,5 lần Hóc Môn (46,0 tr/m²).	Nếu chỉ dùng một ngưỡng lọc ngoại lai chung sẽ xóa nhầm nhà đúng giá ở trung tâm hoặc bỏ sót tin bất thường ở vùng ven.	Vẽ biểu đồ hộp (Boxplot) theo từng cặp [loại hình × quận/huyện]. Xác lập ngưỡng lọc ngoại lai phân tầng riêng cho từng phân khúc.
3	Hiện tượng đa cộng tuyến giữa các biến quy mô	mat_do_xay = dien_tich_m2 × so_phong. Số phòng vệ sinh có tương quan rất cao với số phòng ngủ (hệ số ~0,73).	Gây bất ổn định ma trận hiệp phương sai, mô hình hồi quy không bóc tách được mức độ đóng góp độc lập của từng biến.	Vẽ ma trận hệ số tương quan Heatmap. Tính hệ số phóng đại phương sai (VIF). Loại bỏ biến phụ thuộc trước khi đưa vào mô hình học máy.
4	Khuyết thiếu thông tin địa danh chi tiết	phuong = Khong_ro ở 5.001 dòng (67,25%). ten_duong = Khong_ro ở 2.884 dòng (38,78%). Có 785 dòng phường chỉ ghi số nguyên.	Không thể one-hot hàng trăm tên đường/phường thừa thớt; nguy cơ đồng nhất sai lệch phường cùng số ở các quận khác nhau.	Gộp 20 quận thành 4–5 vùng chiến lược (Khu Trung tâm, Khu Đông, Khu Tây, Khu Nam, Khu Vùng ven). Chỉ mã hóa các tuyến đường lớn xuất hiện đủ nhiều.
5	Kích thước mặt tiền và hèm chứa nhiều mã -1	mat_tien_m = -1 chiếm 78,31% (5.823 dòng). rong_hem_m = -1 chiếm 88,19% (6.558 dòng).	Mô hình số học sẽ hiểu lầm -1 là kích thước âm; kéo tụt giá trị trung bình toàn cột thành phi lý.	So sánh trực quan đơn giá giữa nhóm có và không có số đo. Đưa biến đánh dấu khuyết (co_tt_mat_tien) vào mô hình; không chuẩn hóa số -1 như biến liên tục.
6	Sai lệch cơ cấu tin đăng giữa hai sàn giao dịch	Tại df_clean: batdongsan chiếm 59,17%, cafeland chiếm 40,83%. CafeLand tập trung nhà riêng ngoại thành; Batdongsan có nhiều tin trung tâm và mặt tiền.	Kết luận về mặt bằng giá toàn thành phố có nguy cơ phản ánh cơ cấu sản cào dữ liệu thay vì bản chất thị trường.	Vẽ biểu đồ so sánh phân bố loại hình và đơn giá giữa hai sàn. Đưa biến nguồn_du_lieu vào kiểm soát hoặc áp dụng phương pháp phân tầng.

7	Chuỗi số còn sót lại trong tiêu đề và mô tả	90,09% tiêu đề sạch và 99,99% mô tả sạch vẫn còn chứa chữ số viết dính liền (ví dụ “2PN”, “4x15m”, “giá 8.5ty”).	Mô hình xử lý ngôn ngữ tự nhiên có thể học vệt giá bán viết tắt trong văn bản, gây rò rỉ thông tin ngầm.	Thống kê các n-gram phổ biến nhất trong văn bản. Kiểm tra và mở rộng bộ lọc Regex che triệt để các cụm số phức tạp trước khi trích xuất vector.
8	Mâu thuẫn ngữ nghĩa giữa đặc điểm hẻm và mặt tiền	Có 1.078 dòng tin (14,50%) đồng thời mang cờ la_hẻm = 1 và la_mat_tien = 1.	Xung đột nhãn phân loại làm giảm độ tin cậy của thuộc tính vị trí nhà ở.	Trích mẫu kiểm tra các câu chứa cả hai từ khóa (ví dụ: “mặt tiền hẻm xe hơi”). Thiết lập quy tắc ưu tiên logic hoặc tạo nhóm vị trí hỗn hợp.
9	Kiểm chứng tính khách quan của bộ lọc 4.452 dòng	Bộ lọc đã loại 4.452 dòng, trong đó có 227 dòng bị loại do có sai số dự đoán thô APE > 50% ở notebook tiền xử lý.	Việc loại bỏ các điểm sai số lớn của mô hình thử nghiệm có thể tạo ra hiện tượng thiên lệch chọn mẫu (selection bias).	Đánh giá phân bố của 227 dòng này xem có tập trung vào quận hay phân khúc đặc thù nào không. Kiểm chứng hiệu năng mô hình trên tập kiểm thử hoàn toàn độc lập.
10	Dữ liệu là lát cắt tĩnh, thiếu chiều thời gian	df_raw và df_clean không có biến ngày đăng. Batdongsan có tin từ 2024–2026 trong khi CafeLand tập trung năm 2026.	Biến động giá theo chu kỳ thị trường và lạm phát có thể bị trộn lẫn vào yếu tố chênh lệch nguồn sản.	Tuyệt đối không ngoại suy xu hướng biến động theo thời gian. Mọi kết luận phân tích trong đồ án đều được định vị rõ là lát cắt tại thời điểm quý 3/2026.

6.1. Tổng kết các xử lý đã hoàn thành ở Bài tập 2

- Quy đổi toàn bộ giá bán và diện tích từ chuỗi văn bản phức tạp sang số thực, thống nhất đơn vị triệu VNĐ và mét vuông.
- Lọc bỏ toàn bộ tin đăng ngoài phạm vi TP.HCM (2.366 tin từ nguồn Batdongsan) và các tin khuyết thiếu giá hoặc diện tích.
- Xác lập mã URL duy nhất 100%, bảo đảm 0 dòng trùng lặp tuyệt đối trên cả hai tập dữ liệu.
- Loại bỏ cột tinh_thanh (zero variance) và cột gia_moi_m2_trieu (data leakage) để bảo vệ tính toàn vẹn của mô hình.
- Chuẩn hóa hệ thống danh mục loại hình bất động sản từ 10 nhãn sai lệch về 8 nhóm phân loại chuẩn tắc.
- Tạo các biến chuyển đổi logarit tự nhiên (log_gia_ban, log_dien_tich), biến tương tác quy mô (mat_do_xay), 7 biến đặc điểm nhà 0/1, và 2 biến đánh dấu dữ liệu điền khuyết.
- Ghi nhận và bảo toàn nhãn nguồn dữ liệu trên từng bản ghi nhằm đáp ứng tiêu chuẩn đối chiếu đa nguồn.

7. KẾ HOẠCH TRIỂN KHAI CHO BÀI TẬP 3 (EDA)

7.1. Kế hoạch 8 biểu đồ trực quan hóa ở Bài tập 3 neo vào các vấn đề chất lượng

Nhóm cam kết xây dựng tối thiểu 8 biểu đồ trực quan hóa dữ liệu (sử dụng thư viện Seaborn và Plotly), đảm bảo đầy đủ tiêu đề, nhãn trục, đơn vị đo lường và kèm theo 2–3 câu nhận xét ý nghĩa kinh tế dưới mỗi hình. Các biểu đồ được thiết kế neo trực tiếp vào 10 vấn đề chất lượng đã nhận diện ở Chương 6:

STT	Biểu đồ trực quan hóa	Gắn với vấn đề	Mục tiêu phân tích và giá trị thông tin cần đạt được
1	Histogram kết hợp KDE của giá bán, trước và sau biến đổi logarit	Mục 6.1	Đánh giá mức độ thu hẹp của đuôi phân phối đất tiền và kiểm tra tính đối xứng của log_gia_ban.
2	Biểu đồ hộp (Boxplot) phân phối giá bán theo 8 loại hình bất động sản	Mục 6.2	Xác định mặt bằng giá giữa các phân khúc và nhận diện các điểm ngoại lai bất thường trong từng nhóm.
3	Biểu đồ cột (Bar chart) xếp hạng trung vị đơn giá theo 20 quận/huyện	Mục 6.2 & Câu hỏi phụ	Khảo sát mức độ phân hóa địa lý và xếp hạng các khu vực có giá trị định giá cao/thấp nhất.
4	Biểu đồ phân tán (Scatter plot) diện tích – giá bán, phân tầng theo vị trí hẻm/mặt tiền	Mục 6.8	Kiểm tra tính tuyến tính của quan hệ giá–diện tích và mức độ tách biệt về giá giữa nhà mặt tiền và hẻm.
5	Ma trận hệ số tương quan nhiệt (Correlation Heatmap) giữa các biến định lượng	Mục 6.3	Phát hiện đa cộng tuyến giữa diện tích, số tầng, mật độ xây, số phòng; chọn lọc biến độc lập tối ưu.
6	Biểu đồ violin phân phối giá theo tình trạng pháp lý (có / không sổ hồng)	Đặc điểm nhà	Kiểm định trực quan xem yếu tố minh bạch pháp lý có tạo ra mức thặng dư giá bán thực tế hay không.

7	Biểu đồ cột nhóm (Grouped Bar) so sánh tỉ lệ tiện ích ô tô vào nhà và mặt tiền giữa 2 sản	Mục 6.6	Kiểm tra sự khác biệt về cơ cấu hàng hóa và phân khúc khách hàng giữa CafeLand và Batdongsan.
8	Bản đồ nhiệt tương tác (Choropleth Map / Treemap) thể hiện giá trị BĐS theo quận	Câu hỏi phụ	Trực quan hóa không gian địa lý trực quan cho phép người dùng quan sát toàn cảnh thị trường TP.HCM.

7.2. Định hướng xây dựng mô hình học máy ở Bài tập 4

- **Tiền xử lý dữ liệu.** Mã hóa One-Hot biến quận/huyện và loại hình. Chuẩn hóa thang đo các biến số liên tục bằng RobustScaler để kháng chịu ngoại lai. Đưa trực tiếp các biến nhị phân 0/1 (tiện ích nhà ở, đánh dấu khuyết thiếu) vào mô hình.
- **Kiến trúc mô hình.** Xây dựng và so sánh hai trường phái thuật toán: (1) Mô hình giải thích (Ridge Regression / Hồi quy tuyến tính trên `log_gia_ban`) để phân tích ý nghĩa và trọng số của các thuộc tính; (2) Mô hình phi tuyến (Random Forest / LightGBM trên `gia_ban`) để nắm bắt tương tác phức tạp giữa vị trí và diện tích.
- **Thước đo đánh giá.** Đánh giá hiệu năng dựa trên các thước đo chuẩn mực: MAE (sai số tuyệt đối trung bình), RMSE (căn bậc hai sai số bình phương trung bình), và R^2 trên tập kiểm thử độc lập (tỉ lệ phân chia 80/20). Khi huấn luyện trên `log`, bắt buộc dùng hàm `exp()` quy đổi về tiền thật trước khi tính sai số.
- **Nguyên tắc phòng ngừa leakage.** Nghiêm cấm tuyệt đối việc sử dụng đơn giá (`gia_moi_m2_trieu`), đường dẫn url, tiêu đề và mô tả văn bản thô chưa che số làm đặc trưng đầu vào để tránh hoàn toàn hiện tượng rò rỉ nhãn.

8. HẠN CHẾ NGHIÊN CỨU VÀ QUY ƯỚC KỸ THUẬT

- Giá bán trong tập dữ liệu là giá chào bán niêm yết trên các website bất động sản, không phải giá giao dịch thực tế tại phòng công chứng. Mọi dự báo giá trị đều mang ý nghĩa là mức giá chào bán tham chiếu trên thị trường trực tuyến.
- Dữ liệu thiếu thông tin lịch sử giao dịch theo thời gian; do đó không thể suy diễn hay dự báo xu hướng biến động giá theo các chu kỳ kinh tế.
- Phạm vi địa lý khảo sát chưa bao phủ đủ 24 quận/huyện cũ của TP.HCM (thiếu huyện Củ Chi, Bình Chánh, Cần Giờ; khu vực ven chỉ có Hóc Môn và Nhà Bè). Không thể ngoại suy mô hình cho toàn bộ vùng nông thôn ngoại thành.
- Các thuộc tính nhị phân trích xuất từ văn bản phản ánh thông tin người đăng tin cung cấp, chưa thể xác minh thực địa. Các cụm từ như “chính chủ”, “gần trường chợ” có thể bị người bán thổi phồng nhằm thu hút sự chú ý.
- Thông tin số điện thoại và tên cá nhân môi giới có thể còn sót lại trong các chuỗi văn bản mô tả dính chữ dù đã lọc các cụm số đứng riêng.
- Tài liệu Từ điển dữ liệu này phản ánh trạng thái dữ liệu đã xác thực tại ngày 16/09/2026. Mọi thay đổi về mã nguồn hoặc cập nhật tệp tin CSV sau thời điểm này cần được chạy lại quy trình kiểm toán tự động.